

## 基于 LSTM 预测信息的在线融资融券组合交易策略

刘伟龙, 张 永, 杨兴雨

(广东工业大学 管理学院, 广州 510520)

**摘 要** 随着国内融资融券市场日渐成熟和金融科技不断进步, 构建智能化的融资融券交易策略成为量化金融领域的重要话题和关键挑战. 该文利用长短期记忆网络 (LSTM) 预测信息构建专家策略, 提出了集成专家意见的在线融资融券组合交易策略. 首先, 使用多个技术指标作为输入变量, 通过 LSTM 神经网络模型预测股价的涨跌趋势. 其次, 考虑投资于单支股票的专家, 根据 LSTM 模型的预测结果构建各专家的买卖策略. 然后, 提出了一种基于专家表现的权重优化模型, 通过求解模型确定每个专家的权重. 最后, 为说明所构建策略的有效性, 利用股票市场历史交易数据进行实证分析. 结果表明所构建的策略能够获得高于基准策略的绩效表现, 并在考虑交易费用的情况下仍能保持优越性.

**关键词** 机器学习; 融资融券; 在线投资组合; LSTM 神经网络

## Online margin trading strategy based on LSTM prediction information

LIU Weilong, ZHANG Yong, YANG Xingyu

(School of Management, Guangdong University of Technology, Guangzhou 510520, China)

**Abstract** With the growing maturity of the domestic margin market and the continuous advancement of financial technology, the development of intelligent margin trading strategies has emerged as a critical topic and challenge in the field of quantitative finance. This article employs long short-term memory (LSTM) networks to construct expert strategies based on predictive information and proposes an online margin portfolio trading strategy that integrates expert opinions. Firstly, multiple technical indicators are utilized as input variables to anticipate the trend of stock prices using the LSTM neural network model. Next, an expert specializing in investing in a single stock is considered, and buying or selling strategies for each expert are formulated based on the LSTM model's prediction results. Then, a weight optimization model based on expert performance is proposed to determine the weight of each expert by solving the model. Finally, to demonstrate the efficacy of the proposed strategy, historical trading data from stock

收稿日期: 2022-04-29

**作者简介:** 刘伟龙 (1994–), 男, 汉, 广东惠州人, 博士研究生, 研究方向: 投资组合优化, E-mail: liuwlweller@outlook.com; 通信作者: 张永 (1981–), 女, 汉, 河南信阳人, 博士, 教授, 研究方向: 在线金融算法, E-mail: zhangy@gdut.edu.cn.

**基金项目:** 国家自然科学基金面上项目 (72371080); 教育部人文社会科学研究基金 (21YJA630117); 广东省基础与应用基础研究基金 (2024A1515012670, 2023A1515012840); 广东省哲学社会科学规划项目 (GD23XGL022)

**Foundation item:** National Natural Science Foundation of China (72371080); Humanities and Social Science Fund of Ministry of Education of China (21YJA630117); Basic and Applied Basic Research Foundation of Guangdong Province (2024A1515012670, 2023A1515012840); Philosophy and Social Sciences Planning Project of Guangdong Province (GD23XGL022)

**中文引用格式:** 刘伟龙, 张永, 杨兴雨. 基于 LSTM 预测信息的在线融资融券组合交易策略 [J]. 系统工程理论与实践, 2024, 44(8): 2493–2508.

**英文引用格式:** Liu W L, Zhang Y, Yang X Y. Online margin trading strategy based on LSTM prediction information[J]. Systems Engineering — Theory & Practice, 2024, 44(8): 2493–2508.

markets is utilized for empirical analysis. The results demonstrate that the developed strategy is capable of achieving better performance than some benchmark strategies, even when taking transaction costs into consideration.

**Keywords** machine learning; margin trading; online portfolio; LSTM neural network

## 1 引言

近年来,资产管理行业在人们日益增长的投资热情驱动下迎来了蓬勃发展.据 McKinsey 报告,全球资产管理规模(asset under management, AUM)在2022年初达到了126万亿的新高,占全球金融资产的28%,较十年前的23%显著提高.中国资产管理行业在近十年也实现了飞跃性的发展.根据中国证券投资基金业协会的数据,在2022年末,中国资产管理规模达到了66.74万亿元,较2014年末(19.86万亿元)的涨幅高达236%.投资组合是资产管理的核心业务之一,旨在通过多样化资产配置方案实现收益最大化和风险最小化.随着金融科技的高速发展,资产管理行业不断地向数字化和智能化转型.大数据背景下,日益增长的数据规模和飞速发展的计算机技术为现代投资组合领域带来机遇和挑战.利用云计算、大数据和人工智能等新兴技术构建智能化投资组合策略,能够有效地把握市场动态和识别风险信号,逐渐成为资产管理行业和量化投资领域的焦点.

投资组合理论旨在解决在不确定环境下如何合理配置资金的投资决策问题.自 Markowitz<sup>[1]</sup>提出均值-方差(mean-variance, MV)模型以来,现代投资组合理论得到了广泛的发展<sup>[2,3]</sup>.传统的投资组合模型通常通过两个阶段来构建投资策略:第一阶段是基于市场信息来估计资产收益的统计分布;第二阶段是根据收益分布的数字特征构建目标函数,并通过求解优化模型来获得投资策略.然而,由于金融市场的复杂性和不确定性,资产收益的统计分布难以准确估计.为了弥补以上不足,Cover<sup>[4]</sup>提出了具有泛证券投资组合性质的UP(universal portfolio)策略,基于竞争分析的框架开启了在线投资组合策略的研究. Helmbold 等<sup>[5]</sup>设计了EG(exponential gradient)策略来追踪表现最好的投资组合,并在理论上证明了策略的泛证券性.张永等<sup>[6]</sup>基于弱集成算法构建了集成有限个专家意见的SAS(single aggregating strategy)策略和MAS(mixture aggregating strategy)策略. Hazan 和 Kale<sup>[7]</sup>基于凹损失函数提出了后悔度最小化的在线投资组合策略,并证明了策略在最坏情况下具有泛证券性.李斌等<sup>[8]</sup>提出了一个基于次梯度投影的泛证券投资组合策略SGP(sub-gradient projection),并证明了策略具有线性时间复杂度和存在后悔度边界.彭子衿和徐维军<sup>[9]</sup>基于 $L_1$ -中位数思想构造了EGLM(exponential gradient via  $L_1$ -median)策略.

为了提升在线投资组合策略的竞争性能,学者们采用了量化金融领域的股价预测技术来构建在线投资组合策略. Li 等<sup>[10]</sup>构建了基于均值回归预测技术的OLMAR(on-line moving average reversion)策略. Huang 等<sup>[11]</sup>提出了基于稳健中值回归技术来提高股价预测技术的RMR(robust median reversion)在线投资组合策略. Guan 和 An<sup>[12]</sup>基于线性回归预测技术提出了LOAD(local adaptive online portfolio system)策略. Lai 等<sup>[13]</sup>基于径向基函数技术提出了AICTR(adaptive input and composite trend representation)在线投资组合策略. Guo 等<sup>[14]</sup>将自适应衰减因子嵌入到移动平均预测技术中,提出了AOLNPM(Adaptive Online Net Profit Maximization)投资组合策略.林虹等<sup>[15]</sup>提出了基于指数平滑法和 $L_1$ -中位数法的CFEG(combination forecasting for exponential gradient)在线投资组合策略.尽管基于股价预测的在线投资组合策略不具有泛证券性,但在数值实验中往往获得比泛证券策略更优异的表现.然而,基于股价预测的在线投资组合策略的表现往往高度依赖于股价预测的精度.因此,提高价格预测的准确性是改进基于股价预测的在线投资组合策略的关键.

机器学习技术能够处理复杂金融数据之间的非线性关系,近年来在金融预测领域得到了广泛关注<sup>[16]</sup>.递归神经网络(RNN)在序列信息处理方面具有优势,更适合被用来处理金融时间序列数据.长短期记忆网络(LSTM)解决了传统RNN梯度消失的问题,赋予了神经网络长期记忆的能力,被广泛应用于金融序列预测问题中. Fischer 和 Krauss<sup>[17]</sup>利用LSTM网络预测股票的涨跌趋势,通过数值分析说明了LSTM网络的优越性. Chen 等<sup>[18]</sup>将文本分析和公众情感分析技术融入到LSTM网络中,构

建了一个股价趋势预测模型. Long 等<sup>[19]</sup> 将基于递归神经网络的深度学习模型应用于股票趋势预测及特征工程问题. Lu 等<sup>[20]</sup> 提出了一个由卷积神经网络、双向 LSTM 网络和注意力机制组成的深度学习模型, 用于预测股票的收盘价. Pang 等<sup>[21]</sup> 提出了一个基于文本处理技术的 LSTM 股价预测模型. 进一步地, 一些学者综合 LSTM 预测技术和传统的投资组合优化理论研究了金融资产配置问题. 传统投资组合模型利用股票历史收益的统计信息估计未来收益的概率分布. 为了克服估计误差带来的影响, 学者们使用神经网络技术估计资产收益的均值、方差等参数, 进而通过求解投资组合模型构建投资策略. Wang 等<sup>[22]</sup> 利用 LSTM 模型完成选股问题, 进一步采用 MV 模型构建投资组合策略. Rezaei 等<sup>[23]</sup> 提出一个整合 CEEMD 和 LSTM 技术的股价预测方法, 并基于预测结果构建了 Black-Litterman 投资组合模型. 李宗铭和房勇<sup>[24]</sup> 构建了基于 LSTM 神经网络的行业资产配置模型. Ma 等<sup>[25]</sup> 比较了多个深度学习预测技术在股价预测的性能, 并基于预测结果与 MV 模型构建投资组合策略. 部分学者应用 LSTM 预测技术构建配对交易策略, 获得了远高于市场表现的收益<sup>[26-28]</sup>. 同时, 机器学习模型的预测性能依赖于输入特征的选择. 一些学者引入能够反映金融市场序列信息的技术指标, 获得了优异的预测结果<sup>[29-32]</sup>. 大数据时代下, 技术指标具有易构建、时效强的特点, 可以帮助投资者挖掘金融市场中的有效信息.

2010 年, 沪深交易所正式启动融资融券业务, 标志着中国证券市场“双边交易, 做空获利”时代的到来. 考虑到卖空是一项重要的决策行为, 学者们对允许卖空情况下的最优投资决策进行了理论研究<sup>[33,34]</sup>. 近年来, 学者们探讨了中国融资融券业务的制度模式及其对金融市场的影响<sup>[35-37]</sup>, 说明了两融业务在价格发现、市场稳定、风险管理等方面的重要意义. 从投资者的角度来看, 构建合理的融资融券交易策略以适应“双边交易, 做空获利”的投资环境至关重要. LSTM 神经网络在股票价格预测和传统投资组合优化领域取得了巨大成功, 但将其应用于在线投资组合问题的研究还较为有限. 显然, LSTM 预测技术可以有效提高股价预测的准确性, 是改进基于预测的投资组合策略的有效工具. 然而, 由于两融业务的复杂性, 利用 LSTM 预测信息构建适合实际投资环境下的融资融券交易策略仍然存在挑战. 为了应对这一挑战, 本文提出一个集成 LSTM 预测信息的在线融资融券组合策略. 该策略为每支股票构建单一资产交易专家, 基于 LSTM 预测信息给出专家买卖信号, 并通过整合专家意见构建投资策略. 策略的具体思路如下: 首先, 构建了贴合中国融资融券交易体制的投资约束. 其次, 设计了一个基于技术指标输入的 LSTM 股票趋势预测模型, 为投资者提供股价的预测信息. 然后, 为每个资产定义一个单一资产交易专家, 并根据预测结果制定专家策略. 接着, 提出了一种基于专家表现的权重优化模型, 为表现较好的专家分配更高的决策权重. 最后, 通过求解优化模型确定各专家的权重, 结合专家意见构建投资者下一期的融资融券组合交易策略.

本文利用 LSTM 网络的预测信息构建专家策略, 提出了一个集成专家意见的在线融资融券组合交易策略. 论文主要贡献如下: 第一, 分析了保证金交易模式下融资融券交易的具体操作过程, 构建了贴合中国融资融券交易市场的投资约束; 第二, 提出了一个基于 LSTM 网络和技术指标分析的股价趋势预测模型, 通过 LSTM 神经网络有效挖掘历史交易数据中的序列信息; 第三, 利用 LSTM 模型的预测结果设计单资产交易策略的专家意见, 并构建了一个专家权重优化模型来赋予表现优异的专家更高的权重, 有效地将 LSTM 强大的金融序列预测能力纳入在线投资决策的框架中; 第四, 给出了专家权重优化模型的解析解, 以保证所提出策略具有较低的计算复杂度, 能够适用于大规模、时效性强的高频交易市场.

本文后续章节安排如下: 第 2 节提出一个基于 LSTM 神经网络的价格趋势预测模型. 第 3 节构建集成单资产交易专家意见的在线融资融券组合交易策略. 第 4 节利用证券市场的历史交易数据进行了实证分析. 第 5 节总结了论文.

## 2 基于 LSTM 网络的股价趋势预测模型

本文旨在提出一个集成专家意见的在线投资组合策略. 策略的核心思想是为每支股票构建单资产交易专家, 通过赋予专家不同的决策权重来构建融资融券交易模式下的投资组合. 在每个决策阶段, 专家会预测股票价格的涨跌趋势, 并根据预测结果执行买入或者做空的单资产投资策略. 本节首先提出基

于 LSTM 网络的股价涨跌预测模型, 用于协助专家做出决策. 不失一般性, 假设一个投资期为一天.

## 2.1 网络结构

预测模型由一个 LSTM 神经单元和一个全连接层构成, 具体结构如图 1 所示. 为便于论述, 首先介绍神经网络中的相关记号:

- $\tilde{\mathbf{x}}_t \in \mathbb{R}^m$  表示第  $t$  天神经网络模型的输入特征向量, 其中  $m \in \mathbb{Z}^+$  表示输入特征个数;

- $\Theta_{f,x}, \Theta_{s,x}, \Theta_{i,x}, \Theta_{o,x} \in \mathbb{R}^{m \times h}, \Theta_{f,h}, \Theta_{s,h}, \Theta_{i,h}, \Theta_{o,h} \in \mathbb{R}^{h \times h}$  表示 LSTM 单元的权值矩阵, 其中  $h \in \mathbb{Z}^+$  表示 LSTM 单元输出维度;

- $\mathbf{b}_f, \mathbf{b}_s, \mathbf{b}_i, \mathbf{b}_o \in \mathbb{R}^h$  表示 LSTM 单元的偏置向量;

- $\mathbf{f}_t, \mathbf{i}_t, \mathbf{o}_t \in \mathbb{R}^h$  分别表示遗忘门、输入门、输出门的输出向量;

- $\mathbf{s}_t, \tilde{\mathbf{s}}_t \in \mathbb{R}^h$  分别表示细胞状态向量及其候选信息向量;

- $\mathbf{h}_t \in \mathbb{R}^h$  表示 LSTM 单元的输出向量;

- $\Theta_p \in \mathbb{R}^h$  表示全连接层的权值向量;

- $b_p \in \mathbb{R}$  表示全连接层的偏置项;

- $\Theta$  表示预测模型所有待优化参数的集合;

- $P_t(\Theta) \in (0, 1)$  表示在给定参数集合  $\Theta$  的情况下, 股票在第  $t$  天上涨概率的预测值.

LSTM 网络预测模型在第  $t$  个决策阶段的具体运行过程归纳为如下五步:

1) 计算遗忘门中的输出向量  $\mathbf{f}_t$ , 即:

$$\mathbf{f}_t = \text{sigmoid}(\Theta_{f,x}^T \tilde{\mathbf{x}}_t + \Theta_{f,h}^T \mathbf{h}_{t-1} + \mathbf{b}_f), \quad (1)$$

其中  $\mathbf{h}_0$  为元素全为 0 的  $n$  维向量,  $(\cdot)^T$  表示向量或者矩阵  $(\cdot)$  的转置.

2) 分别确定细胞状态的候选信息  $\tilde{\mathbf{s}}_t$  及输入门的输出向量  $\mathbf{i}_t$ , 即:

$$\tilde{\mathbf{s}}_t = \tanh(\Theta_{s,x}^T \tilde{\mathbf{x}}_t + \Theta_{s,h}^T \mathbf{h}_{t-1} + \mathbf{b}_s), \quad (2)$$

$$\mathbf{i}_t = \text{sigmoid}(\Theta_{i,x}^T \tilde{\mathbf{x}}_t + \Theta_{i,h}^T \mathbf{h}_{t-1} + \mathbf{b}_i). \quad (3)$$

3) 通过以上信息更新细胞状态  $\mathbf{s}_t$ , 即:

$$\mathbf{s}_t = \mathbf{f}_t \circ \mathbf{s}_{t-1} + \mathbf{i}_t \circ \tilde{\mathbf{s}}_t, \quad (4)$$

其中  $\mathbf{s}_0$  为元素全为 0 的  $n$  维向量,  $\circ$  表示 Hadamard 乘积.

4) 确定细胞单元的输出信息  $\mathbf{h}_t$ , 即:

$$\mathbf{o}_t = \text{sigmoid}(\Theta_{o,x}^T \tilde{\mathbf{x}}_t + \Theta_{o,h}^T \mathbf{h}_{t-1} + \mathbf{b}_o), \quad (5)$$

$$\mathbf{h}_t = \mathbf{o}_t \circ \tanh(\mathbf{s}_t). \quad (6)$$

5) 通过全连接层计算股票在第  $t$  天的上涨概率的预测值  $P_t(\Theta)$ , 即:

$$P_t(\Theta) = \text{sigmoid}(\Theta_p^T \mathbf{h}_t + b_p). \quad (7)$$




图 1 LSTM 神经网络预测模型框架图

## 2.2 技术指标

为了挖掘股票市场中历史数据与价格趋势的关系, 本文基于量化金融领域常用的技术指标构建 LSTM 网络的输入特征. 使用的基础数据为股票交易数据, 包括开盘价、收盘价、最高价、最低价和成交量. 根据股票在过去一段时间的交易数据构建了 11 个常用的技术指标, 并从中提取了 23 个数值特征. 技术指标及相关特征名称见表 1, 具体的计算方式在附录 1 中给出.

表 1 技术指标汇总表

| 指标编号 | 指标名称     | 指标简称 | 特征名称               | 特征记号       |
|------|----------|------|--------------------|------------|
| 1    | 相对变化率    | RCR  | 开盘价 RCR            | $x_{t,1}$  |
|      |          |      | 最高价 RCR            | $x_{t,2}$  |
|      |          |      | 最低价 RCR            | $x_{t,3}$  |
|      |          |      | 收盘价 RCR            | $x_{t,4}$  |
|      |          |      | 成交量 RCR            | $x_{t,5}$  |
| 2    | 简单移动平均   | SMA  | 5 天的 SMA           | $x_{t,6}$  |
|      |          |      | 10 天的 SMA          | $x_{t,7}$  |
|      |          |      | 20 天的 SMA          | $x_{t,8}$  |
| 3    | 指数移动平均   | EMA  | 5 天的 EMA           | $x_{t,9}$  |
|      |          |      | 10 天的 EMA          | $x_{t,10}$ |
|      |          |      | 20 天的 EMA          | $x_{t,11}$ |
| 4    | 日内动能指数   | IMI  | 14 天的 IMI          | $x_{t,12}$ |
| 5    | 异同移动平均   | MACD | 12 天与 26 天的离差值 DIF | $x_{t,13}$ |
|      |          |      | 9 天的离差平均值 DEM      | $x_{t,14}$ |
|      |          |      | 柱状线 BAR            | $x_{t,15}$ |
| 6    | 相对强弱指数   | RSI  | 14 天的 RSI          | $x_{t,16}$ |
| 7    | 顺势指数     | CCI  | 20 天的 CCI          | $x_{t,17}$ |
| 8    | 威廉指数     | WR   | 30 天的 WR           | $x_{t,18}$ |
| 9    | KDJ 随机指标 | KDJ  | 24 天的 K 值          | $x_{t,19}$ |
|      |          |      | 24 天的 D 值          | $x_{t,20}$ |
|      |          |      | 24 天的 J 值          | $x_{t,21}$ |
| 10   | 成交量变异率   | VR   | 24 天的 VR           | $x_{t,22}$ |
| 11   | 成交量震荡指标  | VOSC | 12 天与 26 天的 VOSC   | $x_{t,23}$ |

## 2.3 模型训练

记训练窗口长度为  $T_0$  天, 测试窗口长度为  $T$  天, 即采用近期  $T_0$  天的历史数据预测股票后续  $T$  天的涨跌情况. 股票在第  $t$  天的特征向量记为  $\mathbf{x}_t = (x_{t,1}, \dots, x_{t,23})^T$ . 为了避免量纲不一致带来的预测误差, 对输入特征值基于训练数据进行标准化处理:

$$\tilde{x}_{t,j} = \frac{x_{t,j} - m_j}{d_j}, \quad t = 1, \dots, T_0 + T, \quad j = 1, \dots, 23, \quad (8)$$

其中  $m_j, d_j$  分别为第  $j$  个特征在训练窗口的均值和标准差<sup>1</sup>.

使用符号  $\Theta$  表示 LSTM 网络预测模型所有待优化参数的集合, 共包含 14 个元素: LSTM 单元中的 8 个权值矩阵, 4 个偏置向量, 以及全连接层的 1 个权值矩阵和 1 个偏置项, 即:

$$\Theta = \{\Theta_{f,x}, \Theta_{s,x}, \Theta_{i,x}, \Theta_{o,x}, \Theta_{f,h}, \Theta_{s,h}, \Theta_{i,h}, \Theta_{o,h}, \mathbf{b}_f, \mathbf{b}_s, \mathbf{b}_i, \mathbf{b}_o, \Theta_p, b_p\}.$$

假设一组训练数据为  $(\tilde{\mathbf{x}}_1, y_1), \dots, (\tilde{\mathbf{x}}_{T_0}, y_{T_0})$ , 其中  $\tilde{\mathbf{x}}_t$  为股票第  $t$  天的特征向量,  $y_t$  是一个 0-1 指示变量, 表示股票在第  $t$  期是否上涨. 在给定参数集合  $\Theta$  的情况下, 可以利用式 (1)~(7), 逐步将  $\tilde{\mathbf{x}}_1, \dots, \tilde{\mathbf{x}}_{T_0}$

<sup>1</sup> 为了避免因数据泄露所带来的预测偏差, 标准化的均值和标准差仅基于训练数据计算, 而非训练 + 测试数据.

输入至 LSTM 模型中, 获得股票在训练数据中上涨概率的预测值  $P_1(\Theta), \dots, P_{T_0}(\Theta)$ . 采用二分类问题中常用的交叉熵函数作为损失函数, 刻画上涨概率的预测值  $P_t(\Theta)$  与真实标签数据  $y_t$  之间的误差, 即:

$$L(\Theta) = \frac{1}{T_0} \sum_{t=1}^{T_0} -(y_t \ln P_t(\Theta) + (1 - y_t) \ln(1 - P_t(\Theta))). \quad (9)$$

损失值  $L(\Theta)$  越小, 意味着预测模型在训练数据中的拟合效果越好. 模型训练的目标是寻求最优权重集合来最小化损失值, 因此, 训练过程可以表示为优化问题  $\min_{\Theta} L(\Theta)$ .

采用梯度下降算法求解模型的最优参数集合. 记最大迭代次数为  $g_{\max}$ , 算法在第  $v$  次迭代前的参数集合为  $\Theta_v, v = 1, \dots, g_{\max}$ . 对于任意元素  $\theta_v \in \Theta_v$ , 算法参数的第  $v$  次迭代表示为:

$$\theta_{v+1} = \theta_v - \alpha \cdot \frac{\partial L(\Theta_v)}{\partial \theta_v}, v = 1, \dots, g_{\max}, \quad (10)$$

其中初始状态  $\Theta_0$  的 14 个元素基于标准正态分布随机生成,  $\alpha$  为学习率, 其初始值设为 0.01, 后续由 Adam 优化器<sup>[38]</sup> 自动调整. 当  $g_{\max}$  足够大时, 算法将收敛并得到神经网络模型的最优参数集合  $\Theta^*$ . 在测试阶段, 依次输入后续  $T$  天的最新股票数据, 并利用最优参数集合  $\Theta^*$  和式 (1)~(7) 计算股票上涨概率的预测值  $P_{T_0+1}(\Theta_i^*), \dots, P_{T_0+T}(\Theta_i^*)$ .

### 3 在线融资融券组合交易策略

本节提出一个集成专家意见的在线融资融券组合交易策略. 融资交易是指投资者向证券公司借入资金并购买股票, 而融券交易则是指投资者向证券公司借入证券进行卖出操作. 相比实际交易金额, 投资者只需缴纳较低的保证金, 因此可以通过保证金机制实现杠杆投资. 考虑一个包含  $n$  支股票的在线投资组合问题. 记融资保证金比例为  $\delta$ , 表示在融资交易中, 投资者的保证金与所借资金的比例. 以 1 单位的保证金进行融资业务时, 投资者可以借入价值  $1/\delta$  的资金, 从而持有价值为保证金的  $1/\delta$  倍的股票. 记融券保证金比例  $\mu$ , 表示在融券交易中, 投资者的保证金与所借证券价值的比例. 以 1 单位的保证金进行融券业务, 投资者可以借入价值  $1/\mu$  的证券, 即投资者可以通过融券业务卖空价值为保证金的  $1/\mu$  倍的股票. 保证金比例  $\delta$  和  $\mu$  是由相关监管部门和券商规定的.

以中国交易市场为例. 《上海证券交易所融资融券交易实施细则》规定, 在融资交易中, 融资保证金比例不得低于 100%, 而在融券交易中, 融券保证金比例不得低于 50%. 如果投资者仅使用现金作为保证金, 则有  $\delta = 1$  和  $\mu = 0.5$ . 考虑一个更加复杂的融资情况: 假设投资者在投资股票 A 时先用自身资产买入股票 A, 再将所持有的股票作为担保物进行融资. 根据《细则》第三十六条, 假定股票充当保证金的折算率为 65%. 在这种情况下, 投资者用 1 元钱作为本金, 可以买入价值 1 元的股票 A, 再以持有的股票 A 充当保证金, 融资购买价值 0.65 的股票 A. 此时, 投资者用 1 元作为保证金, 实际购入了价值为 1.65 的股票. 在这种情况下, 只需要将融资保证金比例设为  $\delta = 1/1.65 = 0.606$  即可. 为简化问题, 本文仅考虑使用现金作为融券保证金的情况. 同时, 《细则》规定, 除用来买券还券外, 投资者融券卖出所得价款仅可以用来买入交易所和券商认可的高流动性证券. 目前国内券商对于可充抵保证金证券名单的选取非常严格. 例如, 在广发证券和国金证券上, 融券卖出所得资金仅可以用于买券还券和购买券商指定的几款货币基金. 为了便于建模, 本文假定融券卖出所得价款仅限于在下一投资期用来买券还券. 在这种情况下, 未结算相关融资融券交易前, 投资者用于充当保证金的资金和融券卖出所得资金将被视为担保物暂时冻结.

综上所述, 在融资融券交易中, 投资者需要面对两方面的决策: 1) 确定每支股票的投资方向 (融资买入或融券卖出); 2) 确定每支股票的投资份额. 针对融资融券问题的建模, 提出以下模型假设:

**假设 1** 假设投资者在第  $t$  期的投资策略表示为投资比例向量  $\mathbf{b}_t = (b_{t,1}, \dots, b_{t,n})^T$ , 并满足约束条件  $\sum_{i=1}^n |b_{t,i}| = 1$ , 其中  $b_{t,i}$  的正负号表示对第  $i$  支股票投资方向 (融资买入或者融券卖空),  $b_{t,i}$  的绝对值表示第  $i$  支股票上的保证金占投资者本金的比例.

基于以上模型假设, 投资者在每一期期初做出决策时, 将所有财富都拿来当保证金, 并且在投资期

之间不再进行二次投资决策. 当  $b_{t,i} \geq 0$  时, 表示以投资比例  $b_{t,i}$  作为保证金对第  $i$  支股票进行融资投资; 而  $b_{t,i} < 0$  表示以投资比例  $-b_{t,i}$  作为保证金对第  $i$  支股票进行融券投资. 投资者将可支配的本金分配至备选股票上充当保证金, 因此所有股票上的保证金比例之和为 1, 即  $\sum_{i=1}^n |b_{t,i}| = 1$ .

定义所有投资策略的集合为  $B = \{\mathbf{b} = (b_1, \dots, b_n)^T : \sum_{i=1}^n |b_i| = 1\}$ . 用向量  $\mathbf{r}_t = (r_{t,1}, \dots, r_{t,n})^T$  表示  $n$  支股票在第  $t$  天的收益率向量, 其中  $r_{t,i}$  为第  $i$  支股票在第  $t$  天的收益率. 在线投资者在第  $t$  天以策略  $\mathbf{b}_t \in B$  进行投资, 其对数累积财富更新公式为:

$$G_t = G_{t-1} + \ln \left( 1 + \sum_{i=1}^n \left( \frac{b_{t,i}^+}{\delta} - \frac{b_{t,i}^-}{\mu} \right) r_{t,i} \right), \quad (11)$$

其中  $G_0 = 0$ ,  $b_{t,i}^+ = \max\{b_{t,i}, 0\}$ ,  $b_{t,i}^- = \max\{-b_{t,i}, 0\}$ .

基于单资产交易专家构建专家池, 即假设有  $n$  个专家. 记专家下标集合为  $E = \{1, \dots, n\}$ . 在每个决策阶段, 专家预测股票的涨跌趋势, 然后根据预测结果, 看涨股价时买入股票, 反之则卖空股票. 本文采用第 2 节提出的 LSTM 神经网络模型进行股价涨跌趋势预测. 首先, 专家  $i$  ( $i = 1, \dots, n$ ) 利用第  $i$  支股票最近  $T_0$  天的历史数据进行训练, 得到 LSTM 神经网络的最优参数集合  $\Theta_i^*$ . 其次, 在后续的  $T$  天, 依次获取第  $i$  支股票的最新交易数据, 根据最优参数集合  $\Theta_i^*$  计算该股票在第  $t$  ( $t = 1, \dots, T$ ) 天的上涨概率  $P_{t,i}(\Theta_i^*)$ . 若  $P_{t,i}(\Theta_i^*) > 0.5$ , 专家  $i$  看涨股票并构建买入策略; 否则, 专家  $i$  看跌股票并构建做空策略. 记  $\mathbf{e}_i$  为第  $i$  个元素为 1 其它为 0 的  $n$  维向量, 则第  $t$  天第  $i$  个专家策略表示为:

$$\mathbf{ES}_{t,i} = \begin{cases} \mathbf{e}_i, & P_{t,i}(\Theta_i^*) > 0.5, \\ -\mathbf{e}_i, & P_{t,i}(\Theta_i^*) \leq 0.5. \end{cases} \quad (12)$$

为保证最优参数集合  $\Theta_i^*$  的时效性, 每隔  $T$  天对 LSTM 神经网络进行重新训练.

投资者通过赋予各个专家不同的权重, 集成专家意见构建在线投资策略. 记  $w_{t,i}$  为第  $t$  天专家  $i$  的权重, 表示投资者对于该专家意见的看重程度. 专家权重  $w_{t,i}$  越大, 投资者会将更多的资金投资于第  $i$  支股票. 对于执行融资买入还是融券卖出交易, 依据的是专家  $i$  看涨还是看跌该股票, 而与专家权重的正负无关. 具体而言, 通过式 (13) 计算投资者在第  $t$  天的投资策略:

$$\mathbf{b}_t = \sum_{i=1}^n w_{t,i} \mathbf{ES}_{t,i}. \quad (13)$$

当专家  $i$  看涨股票时, 专家策略为  $\mathbf{ES}_{t,i} = \mathbf{e}_i$ . 根据式 (13), 此时第  $i$  支股票的投资比例为  $b_{t,i} = w_{t,i}$ , 表示以  $w_{t,i}$  的财富比例作为保证金进行融资买入; 反之, 当专家  $i$  看跌股票时, 专家策略为  $\mathbf{ES}_{t,i} = -\mathbf{e}_i$ , 此时有  $b_{t,i} = -w_{t,i}$ , 表示以  $w_{t,i}$  的财富比例作为保证金进行融券卖出.

投资者在决策过程中需要解决两个问题: 一是如何评价专家策略的近期表现, 二是如何确定各个专家的权重. 对于第一个问题, 可以根据专家策略在近期一段时间的对数累积财富对其进行评价. 记评价窗口长度为  $\eta$ , 专家  $i$  在第  $t$  天末的近  $\eta$  期的对数累积财富为:

$$G_{t,i}^{(\eta)} = \begin{cases} G_{t,i}, & t \leq \eta, \\ G_{t,i} - G_{t-\eta+1,i}, & t > \eta, \end{cases} \quad (14)$$

其中  $G_{t,i} = \sum_{t_1=1}^t \ln(\mathbf{ES}_{t_1,i}^T \mathbf{r}_{t_1})$  表示专家  $i$  在第  $t$  期末的对数累积财富. 针对第二个问题, 构建一个专家权重优化模型 (15) 来确定各个专家的权重:

$$\begin{aligned} \min & \left( - \sum_{i=1}^n \frac{G_{t-1,i}^{(\eta)}}{\max_{1 \leq j \leq n} G_{t-1,j}^{(\eta)}} w_{t,i} + \frac{\gamma}{2} \sum_{i=1}^n w_{t,i}^2 \right) \\ \text{s.t.} & \begin{cases} \sum_{i=1}^n w_{t,i} = 1, \\ w_{t,i} \geq 0, \quad i = 1, \dots, n, \end{cases} \end{aligned} \quad (15)$$



其中专家权重  $w_{t,i}$  为决策变量,  $\gamma > 0$  是分散化系数, 用来衡量投资者在分散化投资方面的倾向程度. 模型优化目标由以下两部分组成:  $-\sum_{i=1}^n \frac{G_{t-1,i}^{(\eta)}}{\max_{1 \leq j \leq n} G_{t-1,j}^{(\eta)}} w_{t,i}$  和  $\frac{\gamma}{2} \sum_{i=1}^n w_{t,i}^2$ . 前者使模型能够追踪近期表现出色的专家, 更加重视其给出的投资建议; 后者则使模型能够综合多个专家意见, 实现分散化投资.

**定理 1** 记  $A_{t,i} = G_{t-1,i}^{(\eta)} / \max_{1 \leq j \leq n} G_{t-1,j}^{(\eta)}$ . 不失一般性, 假设  $A_{t,1} \leq \dots \leq A_{t,n}$ . 优化模型 (15) 的最优解为

$$w_{t,i} = \begin{cases} 0, & i \in \{1, \dots, k-1\}, \\ \frac{\sum_{j=k}^n (A_{t,i} - A_{t,j}) + \gamma}{\gamma(n-k+1)}, & i \in \{k, \dots, n\}, \end{cases} \quad (16)$$

其中  $k = \inf\{i : \sum_{j=i}^n (A_{t,j} - A_{t,i}) < \gamma\}$ .

定理 1 的证明过程见附录 2.

综上所述, 在使用 LSTM 网络预测股价的基础上, 本文构建了一种集成专家意见的在线融资融券组合交易策略, 记为 LSTM-EWO. 该策略首先为每支股票构建一个基于 LSTM 股价涨跌预测的单资产交易策略, 并将其视为专家策略. 然后, 通过求解所提出的专家权重优化模型, 确定每个专家的权重. 最后, 集成各专家的投资意见, 给出具体的决策方案. LSTM-EWO 策略的具体实施流程见图 2.




图 2 LSTM-EWO 策略的具体实施流程

## 4 数值算例

为了进一步说明所提出的 LSTM-EWO 策略的有效性和实用性, 本节利用股票市场的历史交易数据进行数值实验.

### 4.1 数据介绍与参数设置

实验从国内外的股票市场选取了六个具有一定代表性的数据集. 其中, 第一个数据集选自中国上证行业类指数 (SSEII), 共包含 10 个行业类指数; 第二个数据集选自中国沪深 300 行业类指数 (CSI300II), 包含 12 个行业类指数; 第三个数据集选自上证 50 指数 (SSE50) 的成分股, 共 27 只股票; 第四个数据集选自中证 100 指数 (CSI100) 的成分股, 共 51 只股票; 第五个数据集选自中国香港恒生指数 (HSI) 的成分股, 共 41 只股票; 最后一个数据集选自美国道琼斯工业指数 (DJIA) 的成分股, 共 26 只股票. SSEII 和 CSI300II 这两个指数型数据在 2009 年和 2007 年才开始具备较为完整的公布数据, 因此它们的起始年限设为 2009 年和 2007 年. 对于两个中国证券市场的个股数据 (SSE50 和 CSI100), 统一以 2008 年为起始年限. 对于其他国家和地区的两个数据集 (HSI 和 DJIA), 则统一以 2007 年为起始年限. 所有数据集的终止年限都设为 2020 年. 在基于指数成分股选取个股数据的时候, 我们参照了 2020 年指数成分股列表, 剔除了在数据集起始时间后上市以及缺失数据较多的股票. 例如, 上证 50 指数共有 50 家成分股, 在满足相关条件的前提下, 其中的 27 家被纳入了 SSE50 数据集中.

采用了前一天的数据代替所有股票数据的缺失值, 同时对价格数据进行了向后复权复息处理. 将 LSTM 网络的训练窗口长度设为  $T_0 = 800$  天, 测试窗口长度设为  $T = 200$  天. 数据集中前 800 天的数据被视为历史数据, 作为 LSTM 网络的初始训练数据. 因此, 第 801 天被视为在线投资的第一个交易



日. 在网络训练中, 采用了移动窗口技术, 每 200 天作为一个学习期, 在每个学习期的最后一天, 利用最近的 800 天历史数据对 LSTM 网络进行重新训练. 表 2 总结了六个数据集的简要信息.

将 LSTM 隐藏层的单元个数设为  $h = 30$ , 分散化偏好系数设为  $\gamma = 1$ , 专家评价窗口长度设为  $\eta = 200$ . 根据《上海证券交易所融资融券交易实施细则》, 融资保证金比例不得低于 100%, 而融券保证金比例不得低于 50%. 因此, 我们设定融资保证金比例为 1, 融券保证金比例分别为 1、0.75 和 0.5. 投资者选择的融券保证金比例越低, 表示该投资者越喜欢利用杠杆进行投资, 在某种程度上反映了其风险偏好程度. 本节后续内容安排如下: 第 4.2 节介绍对比策略; 第 4.3 节给出数值实验结果; 第 4.4 节给出考虑交易费用的结果分析; 第 4.5 节将对模型参数进行敏感性分析, 说明所提出策略的稳定性, 为策略实际应用过程中参数选取提供参考.

表 2 六个数据集的简要信息

| 简称       | 市场类型 | 国家/地区 | 时间范围                  | 资产个数 | 学习期数 | 交易天数 |
|----------|------|-------|-----------------------|------|------|------|
| SSEII    | 指数   | 中国    | 2009.01.01–2020.12.31 | 10   | 10   | 2000 |
| CSI300II | 指数   | 中国    | 2007.01.01–2020.12.31 | 12   | 12   | 2400 |
| SSE50    | 个股   | 中国    | 2008.01.01–2020.12.31 | 27   | 11   | 2200 |
| CSI100   | 个股   | 中国    | 2008.01.01–2020.12.31 | 51   | 11   | 2200 |
| HSI      | 个股   | 中国香港  | 2007.01.01–2020.12.31 | 41   | 12   | 2400 |
| DJIA     | 个股   | 美国    | 2007.01.01–2020.12.31 | 26   | 14   | 2800 |

## 4.2 对比策略

为了更好地衡量 LSTM-EWO 策略的表现, 比较其与一些基准策略在数值算例中的表现. 采用的对比策略如下:


- 1) Market: 在投资初始将财富均匀地投资于每个资产, 并持有至投资结束;
- 2)  $1/N$ : 等权重策略, 每一期将财富均匀地投资于每个资产;
- 3) Best-Stock: 将所有财富投资于最优股票, 是一个事后的基准策略;
- 4) OLMAR: Li 等<sup>[10]</sup> 提出的在线移动均值回归策略;
- 5) LSTM- $1/N$ : 基于 LSTM 神经网络构建专家意见, 在每一期以均匀权重考虑专家意见;
- 6) MA-EWO: 基于移动平均预测方法给出专家意见, 并通过 EWO 模型确定专家权重.

对比策略中, 1)~4) 为传统投资组合策略, 用于体现引入融券交易的优越性; 5) 采用均匀权重模型替换 LSTM-EWO 策略中的 EWO 专家权重优化模型, 用于反映 EWO 模型的优越性; 6) 采用移动平均预测方法替换 LSTM-EWO 策略中的 LSTM 预测模型, 用于反映 LSTM 网络预测模型的优越性.


## 4.3 实验结果

图 3 展示了策略在六个数据集中的逐日对数累积财富, 其中 LSTM-EWO\_1, LSTM-EWO\_0.75 和 LSTM-EWO\_0.5 分别表示三个不同融券保证金比例下的 LSTM-EWO 策略. 由图 3 可知, LSTM-EWO 策略在所有数据集上均取得了高于其它对比策略的最终对数累积财富, 这表明该策略在不同市场环境下均能表现出色. 具体结果归纳为以下四点: 第一, LSTM-EWO 策略相较于不考虑融券交易的 Market、Best-Stock 和 OLMAR 策略表现更优, 说明合理考虑融券行为有助于投资者获取更高的收益; 第二, LSTM-EWO 和 LSTM- $1/N$  策略在各个数据集上表现良好, 其最终对数累积财富明显高于其他策略; 然而, MA-EWO 策略效果不佳, 其在多个数据集上最终对数累积财富低于 Market 策略. 由此可见, 融券交易是双刃剑, 融券交易策略的表现取决于预测模型的性能. 本文构建的 LSTM 预测网络具有较好的股价涨跌预测精度, 能够帮助投资者在融资融券交易中获取高额回报. 第三, LSTM-EWO 模型的对数累积财富在大部分时间高于 LSTM- $1/N$ , 特别是随着投资时间的推移, 两者的差距变得越来越大. 可见, 相比于均匀权重策略, 本文构建的 EWO 模型在专家赋权上具有更好的性能, 其优势在投资时间达到一定长度后变得更加明显. 最后, 比较不同融券保证金比例下 LSTM-EWO 策略的表现, 发现融


券保证金比例越低, 投资者获得的对数累积财富越高, 说明 LSTM-EWO 策略能够帮助投资者通过杠杆投资获取更高的收益. 综上, 实验结果表明本文所构建的 LSTM-EWO 策略在融资融券交易市场具备有效性和实用性, 可以为投资者提供决策支持.




(a) SSEII




(b) CSI300II




(c) SSE50



(d) CSI100



(e) HSI



(f) DJIA

图3 策略在六个数据集的对数累积财富

通过统计检验方法进一步说明 LSTM-EWO 策略的收益与对比策略的差异性. 具体地, 对不同融券保证金比例  $\mu$  下的 LSTM-EWO 策略与其他对比策略的每日收益进行作差, 得到 LSTM-EWO 策略相对于对比策略的超额收益, 然后使用  $t$  检验方法检验超额收益的均值是否显著为 0. 表 3 列出了 LSTM-EWO 策略相对于对比策略的平均超额收益 MER 和统计检验的  $p$  值. 结果表明, LSTM-EWO 策略在六个数据集中都获得了大于 0 的超额收益, 对应的  $p$  值均小于 0.05, 表明 LSTM-EWO 策略的平均收益显著大于对比策略.

为了评估 LSTM-EWO 策略在规避风险方面的优越性, 引入三个常用的风险调整后的收益指标: 1) 夏普比率 (sharpe ratio, SR), 定义为以无风险利率为基准的超额收益均值与标准差之间的比值; 2) 信息比率 (information ratio, IR), 定义为以 Market 策略为基准的超额收益均值与标准差之间的比值; 3) 卡玛比率 (calmar ratio, CR), 定义为以无风险利率为基准的超额收益均值与最大回撤率之间的比值. 表 4 给出了不同策略在三个指标上的计算结果. 结果表明, 在所有数据集上, LSTM-EWO 和 LSTM-1/ $N$  策略的夏普比率、信息比率和卡玛比率都远高于其他对比策略; 在大多数数据集上, LSTM-EWO 策略的风险调整后收益高于 LSTM-1/ $N$  策略; 当保证金比例降低时, LSTM-EWO 策略的风险调整后收益存在波动性, 说明策略通过加大杠杆实现更高收益, 但也增加了投资风险. 因此, 融券保证金比例的选择在一定程度上能够反映投资者的风险偏好. 综上所述, LSTM-EWO 策略实现了优异的风险调整后收益, 在规避风险方面表现良好, 能够帮助投资者在收益和风险之间取得平衡.

表 3 统计检验结果

|          | $\mu$ | Market |        | 1/ $N$ |        | Best-Stock |        | OLMAR  |        | MA-EWO |        | LSTM-1/ $N$ |        |
|----------|-------|--------|--------|--------|--------|------------|--------|--------|--------|--------|--------|-------------|--------|
|          |       | MER    | $p$ 值  | MER    | $p$ 值  | MER        | $p$ 值  | MER    | $p$ 值  | MER    | $p$ 值  | MER         | $p$ 值  |
| SSEII    | 1     | 0.0028 | 0.0000 | 0.0028 | 0.0000 | 0.0024     | 0.0000 | 0.0032 | 0.0000 | 0.0039 | 0.0000 | 0.0006      | 0.0015 |
|          | 0.75  | 0.0033 | 0.0000 | 0.0033 | 0.0000 | 0.0029     | 0.0000 | 0.0037 | 0.0000 | 0.0044 | 0.0000 | 0.0010      | 0.0000 |
|          | 0.5   | 0.0042 | 0.0000 | 0.0043 | 0.0000 | 0.0039     | 0.0000 | 0.0047 | 0.0000 | 0.0054 | 0.0000 | 0.0020      | 0.0000 |
| CSI300II | 1     | 0.0037 | 0.0000 | 0.0037 | 0.0000 | 0.0033     | 0.0000 | 0.0043 | 0.0000 | 0.0042 | 0.0000 | 0.0003      | 0.0104 |
|          | 0.75  | 0.0043 | 0.0000 | 0.0044 | 0.0000 | 0.0039     | 0.0000 | 0.0049 | 0.0000 | 0.0048 | 0.0000 | 0.0009      | 0.0000 |
|          | 0.5   | 0.0056 | 0.0000 | 0.0056 | 0.0000 | 0.0051     | 0.0000 | 0.0061 | 0.0000 | 0.0060 | 0.0000 | 0.0021      | 0.0000 |
| SSE50    | 1     | 0.0050 | 0.0000 | 0.0050 | 0.0000 | 0.0043     | 0.0000 | 0.0050 | 0.0000 | 0.0056 | 0.0000 | 0.0016      | 0.0000 |
|          | 0.75  | 0.0104 | 0.0000 | 0.0105 | 0.0000 | 0.0094     | 0.0000 | 0.0110 | 0.0000 | 0.0123 | 0.0000 | 0.0051      | 0.0000 |
|          | 0.5   | 0.0134 | 0.0000 | 0.0134 | 0.0000 | 0.0123     | 0.0000 | 0.0139 | 0.0000 | 0.0153 | 0.0000 | 0.0080      | 0.0000 |
| CSI100   | 1     | 0.0090 | 0.0000 | 0.0090 | 0.0000 | 0.0080     | 0.0000 | 0.0095 | 0.0000 | 0.0109 | 0.0000 | 0.0036      | 0.0000 |
|          | 0.75  | 0.0082 | 0.0000 | 0.0083 | 0.0000 | 0.0073     | 0.0000 | 0.0068 | 0.0000 | 0.0085 | 0.0000 | 0.0042      | 0.0000 |
|          | 0.5   | 0.0104 | 0.0000 | 0.0104 | 0.0000 | 0.0095     | 0.0000 | 0.0090 | 0.0000 | 0.0107 | 0.0000 | 0.0063      | 0.0000 |
| HSI      | 1     | 0.0071 | 0.0000 | 0.0072 | 0.0000 | 0.0062     | 0.0000 | 0.0057 | 0.0000 | 0.0074 | 0.0000 | 0.0031      | 0.0000 |
|          | 0.75  | 0.0082 | 0.0000 | 0.0083 | 0.0000 | 0.0073     | 0.0000 | 0.0068 | 0.0000 | 0.0085 | 0.0000 | 0.0042      | 0.0000 |
|          | 0.5   | 0.0104 | 0.0000 | 0.0104 | 0.0000 | 0.0095     | 0.0000 | 0.0090 | 0.0000 | 0.0107 | 0.0000 | 0.0063      | 0.0000 |
| DJIA     | 1     | 0.0034 | 0.0000 | 0.0034 | 0.0000 | 0.0028     | 0.0000 | 0.0034 | 0.0000 | 0.0038 | 0.0000 | 0.0008      | 0.0000 |
|          | 0.75  | 0.0039 | 0.0000 | 0.0039 | 0.0000 | 0.0034     | 0.0000 | 0.0039 | 0.0000 | 0.0043 | 0.0000 | 0.0013      | 0.0000 |
|          | 0.5   | 0.0050 | 0.0000 | 0.0050 | 0.0000 | 0.0045     | 0.0000 | 0.0050 | 0.0000 | 0.0054 | 0.0000 | 0.0024      | 0.0000 |

#### 4.4 交易费用

交易费用是影响投资策略的重要因素, 特别是在考虑融券交易的情况下可能需要对股票头寸进行大幅度的调整, 从而产生巨额的交易费用. 因此, 考虑交易费用对于验证交易策略的有效性至关重要. 本文借鉴文献 [14] 的方法刻画交易费用. 设交易费用率为  $c$ . 在第  $t$  期期初, 持有的投资组合为  $\hat{\mathbf{b}}_t = \mathbf{b}_{t-1} \circ (1 + \mathbf{r}_t) / (\mathbf{b}_{t-1}^T (1 + \mathbf{r}_t))$ . 将投资组合从  $\hat{\mathbf{b}}_t$  调整至  $\mathbf{b}_t$  产生的交易费用为  $C_t = c \cdot \sum_{i=1}^n (b_{t,i}^+ - b_{t,i}^- - (\hat{b}_{t,i}^+ - \hat{b}_{t,i}^-))$ . 将交易费用率从 0 增加至 0.003, 计算各个策略在六个数据集中的最终对数累积财富, 结果见图 4. 可以发现, Market, 1/ $N$  和 Best-Stock 策略对交易费用不敏感, 其他策略在交易成本增加时, 其最终对数累积财富显著降低. 对于 LSTM-EWO 策略, 其对数累积财富下降的较为平缓, 在相对较高的千分之三交

表4 策略的风险调整后收益指标

| 数据集      | 指标 | Market | 1/N     | Best-Stock | OLMAR   | MA-EWO  | LSTM-1/N | LSTM-EWO_1    | LSTM-EWO_0.75 | LSTM-EWO_0.5  |
|----------|----|--------|---------|------------|---------|---------|----------|---------------|---------------|---------------|
| SSEII    | SR | 0.0199 | 0.0176  | 0.0419     | -0.0078 | -0.0531 | 0.2762   | 0.3236        | <b>0.3256</b> | 0.3036        |
|          | IR | -      | -0.0317 | 0.0449     | -0.0477 | -0.0564 | 0.1177   | 0.1640        | 0.1670        | <b>0.1707</b> |
|          | CR | 0.0006 | 0.0005  | 0.0015     | -0.0002 | -0.0010 | 0.0131   | 0.0131        | 0.0171        | <b>0.0241</b> |
| CSI300II | SR | 0.0096 | 0.0083  | 0.0357     | -0.0237 | -0.0221 | 0.4151   | <b>0.4305</b> | 0.4288        | 0.3932        |
|          | IR | -      | -0.0179 | 0.0464     | -0.0545 | -0.0248 | 0.2249   | <b>0.2352</b> | 0.2342        | 0.2327        |
|          | CR | 0.0003 | 0.0003  | 0.0015     | -0.0006 | -0.0005 | 0.0249   | 0.0193        | 0.0228        | <b>0.0262</b> |
| SSE50    | SR | 0.0409 | 0.0428  | 0.0615     | 0.0197  | 0.0043  | 0.5126   | <b>0.5440</b> | 0.5292        | 0.4741        |
|          | IR | -      | 0.0011  | 0.0384     | -0.0037 | -0.0362 | 0.2146   | <b>0.2859</b> | 0.2846        | 0.2815        |
|          | CR | 0.0013 | 0.0015  | 0.0033     | 0.0007  | -0.0002 | 0.0513   | 0.0614        | <b>0.0773</b> | 0.0529        |
| CSI100   | SR | 0.0401 | 0.0390  | 0.0591     | -0.0011 | -0.0924 | 0.7647   | 0.8036        | <b>0.8075</b> | 0.7566        |
|          | IR | -      | -0.0127 | 0.0461     | -0.0252 | -0.1072 | 0.4104   | <b>0.5438</b> | 0.5366        | 0.5225        |
|          | CR | 0.0014 | 0.0014  | 0.0029     | 0.0000  | -0.0014 | 0.2359   | 0.2101        | 0.2259        | <b>0.2569</b> |
| HSI      | SR | 0.0410 | 0.0414  | 0.0524     | 0.0641  | 0.0227  | 0.4483   | 0.4228        | 0.4478        | <b>0.4744</b> |
|          | IR | -      | -0.0105 | 0.0459     | 0.0547  | -0.0195 | 0.3095   | 0.3712        | 0.3865        | <b>0.4046</b> |
|          | CR | 0.0016 | 0.0014  | 0.0019     | 0.0033  | 0.0009  | 0.1896   | <b>0.1944</b> | 0.1897        | 0.1755        |
| DJIA     | SR | 0.0441 | 0.0437  | 0.0570     | 0.0237  | 0.0088  | 0.4650   | <b>0.4758</b> | 0.4605        | 0.4123        |
|          | IR | -      | -0.0048 | 0.0402     | -0.0009 | -0.0311 | 0.2502   | <b>0.2587</b> | 0.2556        | 0.2507        |
|          | CR | 0.0014 | 0.0014  | 0.0023     | 0.0006  | 0.0003  | 0.0366   | 0.0764        | <b>0.0848</b> | 0.0659        |

易费用率下,它依然可以取得比其他策略更好的收益表现.这表明了本文所提出的策略在考虑交易费用的情况下仍然具有竞争力.此外,在比较不同融券保证金比例下交易费用对 LSTM-EWO 策略的影响时发现,融券保证金比例越低, LSTM-EWO 策略对交易费用率越敏感.这说明杠杆越高的投资者,其投资组合策略调整的幅度越大,因此受到交易费用的影响越大.

#### 4.5 敏感性分析

对模型参数进行敏感性分析对于验证实验结果的稳健性具有重要意义.一方面,这可以说明实验结果不是通过调整参数而得到的,而是策略本身的表现;另一方面,可以评估策略的鲁棒性.本节将对 LSTM-EWO 策略的主要参数进行敏感性分析,包括 LSTM 单元输出维度  $h$ ,训练窗口长度  $T_0$ ,分散化偏好系数  $\gamma$ ,评价窗口长度  $\eta$ .图 5 展示了 LSTM-EWO 策略在不同模型参数下的收益表现.在本节中,融券保证金比例固定为  $\mu = 1$ .


为了分析 LSTM-EWO 策略对 LSTM 单元输出维度  $h$  的敏感性,将  $h$  设为 20 至 50,比较策略在六个数据集中的收益表现,结果如图 5(a) 所示.可以发现,不同  $h$  取值下,策略的最终对数累积财富存在一定波动,但总体上维持不错的表现.根据实验结果,当  $h \in [20, 30]$  时,策略在不同市场环境下都取得了较高的最终对数累积财富,这为模型在实际应用中参数设置提供了一定参考.

为了分析 LSTM-EWO 策略对训练窗口  $T_0$  的敏感性,将  $T_0$  设为 600 至 1400,比较策略在六个数据集中的收益表现.为保证结果的一致性,规定每个数据集中的第 1401 天作为投资的第一天,然后采用移动窗口技术,每隔 200 天使用最新的  $T_0$  天的历史数据对预测模型进行训练,直至所有数据用尽.计算 LSTM-EWO 策略在不同训练窗口长度下的最终对数累积财富,结果如图 5(b) 所示.可以看出,随着训练窗口  $T_0$  的增大,策略在六个数据集中的最终对数累积财富总体呈上升趋势.训练窗口越大,表示更多历史数据被用于 LSTM 模型的训练,有助于提高预测模型的准确度,进而提高策略的样本外表现.本文 4.3 节的实验结果是在训练窗口为 800 的情况下获得的.由图 5(b) 可知,  $T_0 = 800$  并非是刻意选取的最佳参数,这说明前文的实验结果具有可信性.总的来说,使用更大的训练窗口有利于提升 LSTM-EWO 策略的表现,证明了该策略能够发掘历史交易数据中的有效信息,为投资者提供决策支持.


为了分析 LSTM-EWO 策略对分散化偏好系数  $\gamma$  的敏感性,将  $\gamma$  设为 1 至 5,比较策略在六个数据集中的收益表现,结果如图 5(c) 所示.可以看出,随着  $\gamma$  的增大,策略在六个数据集中的最终对数累积财富均呈缓慢下降的趋势.分散化偏好系数越大,表示投资者更趋向于保守地进行分散化投资以规避风险,而非通过集中投资追求更高的收益.这个结果与实际投资过程中的收益与风险并存现象保持一

致. 投资者可以依据自身的风险容忍程度设置该参数.


为了分析 LSTM-EWO 策略对评价窗口长度  $\eta$  的敏感性, 将  $\eta$  设为 100 至 500, 比较策略在六个数据集中的收益表现, 结果如图 5(d) 所示. 如图 5(d) 所示, 策略的表现对参数  $\eta$  不敏感, 在  $\eta \in [100, 500]$  下均有较为平稳的表现.




(a) SSEII




(b) CSI300II




(c) SSE50



(d) CSI100



(e) HSI



(f) DJIA

图 4 不同交易费用率  $c$  下策略的最终对数累积财富




图5 敏感性分析结果示意图

## 5 结论

本文设计了一个集成 LSTM 预测信息的在线融资融券组合交易策略 LSTM-EWO. 考虑一个融资融券账户中的动态投资组合问题. 假设在每一期期初, 投资者将所有可支配资产都拿来做为保证金, 基于保证金交易制度构建投资策略. 首先, 提出了一个以技术指标为输入的 LSTM 神经网络模型来预测候选股票的涨跌趋势. 其次, 创建一个投资于单支股票的专家池, 并根据 LSTM 预测信息提供关于买卖每支股票的专家意见. 然后, 基于专家的近期表现构建了一个权重优化模型, 赋予绩效良好的专家更高的投资决策权重. 最后, 给出了权重优化模型的解析解, 并集成专家意见给出了在线投资者的保证金交易策略. 为了说明 LSTM-EWO 策略的有效性, 使用真实股票数据进行了数值分析. 实验结果表明, LSTM-EWO 策略在国内外多个数据集中均表现出良好的样本外性能. 此外, LSTM-EWO 策略在 0.3% 的交易成本下仍维持较好的收益表现, 说明该策略对交易成本的容忍程度远高于市场的实际交易成本.

未来, 拟在如下两方面扩展本文研究. 第一, 除了技术指标, 尝试将文本信息、基本面信息等作为 LSTM 模型的输入变量, 以提高价格趋势预测的精度. 第二, 在投资组合构建过程, 考虑股票基数约束、最小交易单位约束等现实投资约束, 使模型更契合现实投资环境.

## 参考文献

- [1] Markowitz H. Portfolio selection[J]. Journal of Finance, 1952, 7(1): 77-91.

- [2] 于孝建, 王秀花, 徐维军. 基于滚动经济回撤约束和下半方差的最优投资组合策略 [J]. 系统工程理论与实践, 2018, 38(3): 545–555.  
Yu X J, Wang X H, Xu W J. Optimal portfolio strategy under rolling economic drawdown constraints with lower semi-variance[J]. Systems Engineering — Theory & Practice, 2018, 38(3): 545–555.
- [3] Dai Z F, Kang J. Some new efficient mean-variance portfolio selection models[J]. International Journal of Finance & Economics, 2021, 7: 1–13.
- [4] Cover T M. Universal portfolios[J]. Mathematical Finance, 1991, 1(1): 1–29.
- [5] Helmbold D P, Schapire R E, Singer Y, et al. On-line portfolio selection using multiplicative updates[J]. Mathematical Finance, 1998, 8(4): 325–347.
- [6] 张永, 张卫国, 徐维军, 等. 集成有限个专家意见的在线投资组合策略 [J]. 系统工程理论与实践, 2015, 35(1): 57–66.  
Zhang Y, Zhang W G, Xu W J, et al. Online portfolio selection strategy by aggregating finite expert advices[J]. Systems Engineering — Theory & Practice, 2015, 35(1): 57–66.
- [7] Hazan E, Kale S. An online portfolio selection algorithm with regret logarithmic in price variation[J]. Mathematical Finance, 2015, 25(2): 288–310.
- [8] 李斌, 张迪, 唐松慧. 基于次梯度投影的泛投资组合选择策略 [J]. 管理科学学报, 2018, 21(3): 94–104.  
Li B, Zhang D, Tang S H. Universal portfolio selection strategy based on sub-gradient projection[J]. Journal of Management Sciences in China, 2018, 21(3): 94–104.
- [9] 彭子衿, 徐维军. 基于股价预测的泛证券投资组合策略 [J]. 中国管理科学, 2018, 26(9): 1–10.  
Peng Z J, Xu W J. Universal portfolio strategy based on forecasting price[J]. Chinese Journal of Management Science, 2018, 26(9): 1–10.
- [10] Li B, Hoi S, Sahoo D, et al. Moving average reversion strategy for on-line portfolio selection[J]. Artificial Intelligence, 2015, 222: 104–123.
- [11] Huang D, Zhou J, Li B, et al. Robust median reversion strategy for online portfolio selection[J]. IEEE Transactions on Knowledge and Data Engineering, 2016, 28(9): 2480–2493.
- [12] Guan H, An Z. A local adaptive learning system for online portfolio selection[J]. Knowledge-Based Systems, 2019, 186: 104958.
- [13] Lai Z R, Yang P Y, Fang L, et al. Reweighted price relative tracking system for automatic portfolio optimization[J]. IEEE Transactions on Systems, Man, and Cybernetics: Systems, 2020, 50(11): 4349–4361.
- [14] Guo S N, Gu J W, Ching W K. Adaptive online portfolio selection with transaction costs[J]. European Journal of Operational Research, 2021, 295(3): 1074–1086.
- [15] 林虹, 张永, 杨兴雨, 等. 考虑组合预测股价的泛证券投资组合选择策略 [J]. 管理工程学报, 2023, 37(5): 130–141.  
Lin H, Zhang Y, Yang X Y, et al. Universal portfolio selection strategy based on combination forecasting price[J]. Journal of Industrial Engineering/ Engineering Management, 2023, 37(5): 130–141.
- [16] Ozbayoglu A M, Gudelek M U, Sezer O B. Deep learning for financial applications: A survey[J]. Applied Soft Computing, 2020, 93: 106384.
- [17] Fischer T, Krauss C. Deep learning with long short-term memory networks for financial market predictions[J]. European Journal of Operational Research, 2018, 270(2): 654–669.
- [18] Chen M Y, Liao C H, Hsieh R P. Modeling public mood and emotion: Stock market trend prediction with anticipatory computing approach[J]. Computers in Human Behavior, 2019, 101: 402–408.
- [19] Long W, Lu Z, Cui L. Deep learning-based feature engineering for stock price movement prediction[J]. Knowledge-Based Systems, 2019, 164: 163–173.
- [20] Lu W, Li J, Wang J, et al. A CNN-BiLSTM-AM method for stock price prediction[J]. Neural Computing and Applications, 2021, 33(10): 4741–4753.
- [21] Pang X, Zhou Y, Wang P, et al. An innovative neural network approach for stock market prediction[J]. The Journal of Supercomputing, 2020, 76(3): 2098–2118.
- [22] Wang W, Li W, Zhang N, et al. Portfolio formation with preselection using deep learning from long-term financial data[J]. Expert Systems with Applications, 2020, 143: 113042.
- [23] Rezaei H, Faaljou H, Mansourfar G. Intelligent asset allocation using predictions of deep frequency decomposition[J]. Expert Systems with Applications, 2021, 186: 115715.
- [24] 李宗铭, 房勇. 基于 LSTM 神经网络的行业资产配置模型 [J]. 系统工程理论与实践, 2021, 41(8): 2045–2055.



- Li Z M, Fang Y. Industry asset allocation model based on LSTM neural network[J]. Systems Engineering — Theory & Practice, 2021, 41(8): 2045–2055.
- [25] Ma Y, Han R, Wang W. Portfolio optimization with return prediction using deep learning and machine learning[J]. Expert Systems with Applications, 2021, 165: 113973.
- [26] Chang V, Man X, Xu Q, et al. Pairs trading on different portfolios based on machine learning[J]. Expert Systems, 2021, 38(3): e12649.
- [27] Du J. Mean-variance portfolio optimization with deep learning based-forecasts for cointegrated stocks[J]. Expert Systems with Applications, 2022, 201: 117005.
- [28] Flori A, Regoli D. Revealing pairs-trading opportunities with long short-term memory networks[J]. European Journal of Operational Research, 2021, 295(2): 772–791.
- [29] 李斌, 林彦, 唐闻轩. ML-TEA: 一套基于机器学习和技术分析的量化投资算法 [J]. 系统工程理论与实践, 2017, 37(5): 1089–1100.
- Li B, Lin Y, Tang W X. ML-TEA: A set of quantitative investment algorithms based on machine learning and technical analysis[J]. Systems Engineering — Theory & Practice, 2017, 37(5): 1089–1100.
- [30] Picasso A S, Merello S, Ma Y, et al. Technical analysis and sentiment embeddings for market trend prediction[J]. Expert Systems with Applications, 2019, 135: 60–70.
- [31] Chen W, Jiang M R, Zhang W G, et al. A novel graph convolutional feature based convolutional neural network for stock trend prediction[J]. Information Sciences, 2021, 556: 67–94.
- [32] 戴志锋, 康杰, 王雄. 人民币汇率的可预测性与预测因子选择 [J]. 系统工程理论与实践, 2021, 41(11): 2822–2836.
- Dai Z F, Kang J, Wang X. Predictability of the RMB exchange rate and predictor selection[J]. Systems Engineering — Theory & Practice, 2021, 41(11): 2822–2836.
- [33] Chang K H, Nayat Y M. Behavioral stock portfolio optimization considering holding periods of B-stocks with short-selling[J]. Computers & Operations Research, 2019, 112: 104773.
- [34] Bellalah M, Hakim A, Si K, et al. Long term optimal investment with regime switching: Inflation, information and short sales[J]. Annals of Operations Research, 2022, 313(2): 1373–1386.
- [35] 李科, 徐龙炳, 朱伟骅. 卖空限制与股票错误定价——融资融券制度的证据 [J]. 经济研究, 2014, 49(10): 165–178.
- Li K, Xu L B, Zhu W H. Short-sale constrains and stock mispricing: The evidences from the margin transactions institution[J]. Economic Research Journal, 2014, 49(10): 165–178.
- [36] 胡伦超, 余乐安, 汤铃. 融资融券背景下证券配对交易策略研究——基于协整和距离的两阶段方法 [J]. 中国管理科学, 2016, 24(4): 1–9.
- Hu L C, Yu L A, Tang L. Pairs trading strategy research considering short selling and margin trading: A two-stage approach based on cointegration and distance method[J]. Chinese Journal of Management Science, 2016, 24(4): 1–9.
- [37] 褚剑, 秦璇, 方军雄. 中国式融资融券制度安排与分析师盈利预测乐观偏差 [J]. 管理世界, 2019, 35(1): 151–166.
- Chu J, Qin X, Fang J X. Margin-trading, short-selling and analysts' forecast optimism[J]. Management World, 2019, 35(1): 151–166.
- [38] Kingma D P, Ba J. Adam: A method for Stochastic optimization[C]// 3rd International Conference on Learning Representations — ICLR 2015, San Diego, CA, USA, 7–9 May 2015.

## 附录 1 技术指标的构建过程

记第  $t$  天的开盘价  $o_t$ , 最高价  $h_t$ , 最低价  $l_t$ , 收盘价  $c_t$ , 成交量  $v_t$ . LSTM 神经网络输入特征的具体构建过程如下

### 1) 相对变化率 (relative change rate, RCR)

取开盘价、最高价、最低价、收盘价和成交量在上一天的相对变化率做为输入特征, 即:

$$x_{t,1} = \frac{o_{t-1} - o_{t-2}}{o_{t-2}}, \quad \frac{h_{t-1} - h_{t-2}}{h_{t-2}}, \quad \frac{l_{t-1} - l_{t-2}}{l_{t-2}}, \quad \frac{c_{t-1} - c_{t-2}}{c_{t-2}}, \quad \frac{v_{t-1} - v_{t-2}}{v_{t-2}}.$$

### 2) 简单移动平均收益率 (simple moving average, SMA)

记窗口长度为  $k$  天. 股票在第  $t$  天的简单移动平均值为:

$$\text{SMA}_t(k) = \frac{c_{t-k} + \cdots + c_{t-1}}{k}.$$

分别取  $k = 5, 10$  和  $20$ , 采用股票在对应简单移动平均价格下的收益率作为输入特征, 即:

$$x_{t,6} = \frac{\text{SMA}_t(5) - c_{t-1}}{c_{t-1}}, \quad x_{t,7} = \frac{\text{SMA}_t(10) - c_{t-1}}{c_{t-1}}, \quad x_{t,8} = \frac{\text{SMA}_t(20) - c_{t-1}}{c_{t-1}}.$$

### 3) 指数移动平均收益率 (exponential moving average, EMA)

记窗口长度为  $k$  天. 股票在第  $t$  天的指数移动平均值为:

$$\text{EMA}_t(k) = w_1 c_{t-k} + \cdots + w_k c_{t-1},$$

其中,  $w_1 = \left(\frac{k-1}{k+1}\right)^{k-1}$ ,  $w_j = \frac{2}{k+1} \left(\frac{k-1}{k+1}\right)^{k-j}$ ,  $j = 2, \cdots, k$ . 取  $k = 5, 10$  和  $20$ , 采用股票在对应指数移动平均价格下的收益率作为输入特征, 即

$$x_{t,9} = \frac{\text{EMA}_t(5) - c_{t-1}}{c_{t-1}}, \quad x_{t,10} = \frac{\text{EMA}_t(10) - c_{t-1}}{c_{t-1}}, \quad x_{t,11} = \frac{\text{EMA}_t(20) - c_{t-1}}{c_{t-1}}.$$

### 4) 日内动能指数 (intraday momentum index, IMI)

记窗口长度为  $k$  天. 股票在第  $t$  天的日内动能指数表示为:

$$\text{IMI}_t(k) = \frac{\sum_{d=t-k}^{t-1} \text{Gain}_d}{\sum_{d=t-k}^{t-1} (\text{Gain}_d + \text{Loss}_d)},$$

其中,  $\text{Gain}_d = \max\{c_d - c_{d-1}, 0\}$ ,  $\text{Loss}_d = \max\{c_{d-1} - c_d, 0\}$ . 取  $k = 14$ , 采用股票的日内动能指数作为输入特征, 即  $x_{t,12} = \text{IMI}_t(14)$ .

### 5) 异同移动平均 (moving average convergence / divergence, MACD)

异同移动平均由离差值 (DIF)、离差平均值 (DEM) 和柱状线 (BAR) 组成. 记快速窗口长度为  $k_1$  天, 慢速窗口长度为  $k_2$  天, 离差窗口长度为  $k_3$  天. 股票在第  $t$  天的离差值定义为收盘价的快速指数移动平均值和慢速指数移动平均值的差值, 即:

$$\text{DIF}_t(k_1, k_2) = \text{EMA}_t(k_1) - \text{EMA}_t(k_2).$$

股票在第  $t$  天的离差平均值定义为近期  $k_3$  天离差值的指数移动平均值, 即:

$$\text{DEM}_t(k_1, k_2, k_3) = w_1 \text{DIF}_{t-k_3+1}(k_1, k_2) + \cdots + w_{k_3} \text{DIF}_t(k_1, k_2),$$

其中,  $w_1 = \left(\frac{k_3-1}{k_3+1}\right)^{k_3-1}$ ,  $w_j = \frac{2}{k_3+1} \left(\frac{k_3-1}{k_3+1}\right)^{k_3-j}$ ,  $j = 2, \cdots, k_3$ ; 股票在第  $t$  天的柱状线定义为:

$$\text{BAR}_t(k_1, k_2, k_3) = 2(\text{DIF}_t(k_1, k_2) - \text{DEM}_t(k_1, k_2, k_3)).$$

取  $k_1 = 12, k_2 = 26, k_3 = 9$ , 采用股票的离差值、离差平均值和柱状线作为输入特征, 即:

$$x_{t,13} = \text{DIF}_t(k_1, k_2), x_{t,14} = \text{DEM}_t(k_1, k_2, k_3), x_{t,15} = \text{BAR}_t(k_1, k_2, k_3).$$

6) 相对强弱指数 (relative strength index, RSI)

记窗口长度为  $k$  天. 股票在第  $t$  天的相对强弱指数定义为:

$$\text{RSI}_t(k) = 100 - \frac{100}{1 + \sum_{d=t-k}^{t-1} \text{Gain}_d / \sum_{d=t-k}^{t-1} (\text{Gain}_d + \text{Loss}_d)}.$$

取  $k = 14$ , 采用股票的相对强弱指数作为输入特征, 即  $x_{t,16} = \text{RSI}_t(14)$ .

7) 顺势指标 (commodity channel index, CCI)

记窗口长度为  $k$  天. 股票第  $t$  天的顺势指标定义为

$$\text{CCI}_t(k) = \frac{\text{PT}_{t-1} - \text{MA}_{t,k}}{0.015 \text{MD}_{t,k}},$$

其中,  $\text{PT}_d = \frac{h_d + l_d + c_d}{3}$ ,  $d = t-k, \dots, t-1$ ,  $\text{MA}_{t,k} = \frac{\sum_{d=t-k}^{t-1} \text{PT}_d}{k}$ ,  $\text{MD}_{t,k} = \frac{\sum_{d=t-k}^{t-1} |\text{PT}_d - \text{MD}_{t,k}|}{k}$ . 取  $k = 20$ , 采取股票的顺势指标作为输入特征, 即  $x_{t,17} = \text{CCI}_t(20)$ .

8) 威廉指标 (Williams % R, WR)

记窗口长度为  $k$  天. 股票第  $t$  天的威廉指数定义为:

$$\text{WR}_t(k) = \frac{\max_{t-k \leq d \leq t-1} h_d - c_{t-1}}{\max_{t-k \leq d \leq t-1} h_d - \min_{t-k \leq d \leq t-1} l_d} \times 100.$$

取  $k = 30$ , 采用股票威廉指标作为输入特征, 即  $x_{t,18} = \text{WR}_t(30)$ .

9) KDJ 随机指标 (KDJ stochastic indicator, KDJ)

记窗口长度为  $k$  天. 股票第  $t$  天的未成熟随机值定义为:

$$\text{RSV}_t(k) = \frac{c_{t-1} - \max_{t-k \leq d \leq t-1} l_d}{\max_{t-k \leq d \leq t-1} h_d - \min_{t-k \leq d \leq t-1} l_d} \times 100.$$

股票在第  $t$  天的  $K$  值,  $D$  值和  $J$  值分别为:

$$K_t(k) = \frac{2}{3} K_{t-1}(k) + \frac{1}{3} \text{RSV}_t(k), D_t(k) = \frac{2}{3} D_{t-1}(k) + \frac{1}{3} K_t(k), J_t(k) = 3K_t(k) - 2D_t(k),$$

其中首天的  $K$  值和  $D$  值均取 50. 取  $k = 24$ , 采用股票 KDJ 随机指标下的  $K$  值,  $D$  值和  $J$  作为输入指标, 即:

$$x_{t,19} = K_t(24), x_{t,20} = D_t(24), x_{t,21} = J_t(24).$$

10) 成交量变异率 (volatility volume ratio, VR)

记窗口长度为  $k$  天. 股票在第  $t$  天的成交量变异率为:

$$\text{VR}_t(k) = \frac{\text{AVS}_t(k) + 0.5 \text{CVS}_t(k)}{\text{BVS}_t(k) + 0.5 \text{CVS}_t(k)} \times 100.$$

其中  $\text{AVS}_t(k) = \sum_{d=t-k}^{t-1} v_d I(c_d > c_{d-1})$  为股票在上涨期的交易量总和,  $\text{BVS}_t(k) = \sum_{d=t-k}^{t-1} v_d I(c_d < c_{d-1})$  为股票在下跌期的交易量总和,  $\text{CVS}_t(k) = \sum_{d=t-k}^{t-1} v_d I(c_d = c_{d-1})$  为股票在平盘期的交易量总和,  $I(\cdot)$  为指示函数. 取  $k = 24$ , 采用股票的成交量变异率作为输入特征, 即  $x_{t,22} = \text{VR}_t(24)$ .

11) 成交量震荡指标 (volume oscillator, VOSC)

记短期窗口长度为  $k_1$  天, 长期窗口长度为  $k_2$ . 股票在第  $t$  天的成交量震荡指标表示为:

$$\text{VOSC}_t(k_1, k_2) = \frac{\sum_{d=t-k_1}^{t-1} v_d / k_1 - \sum_{d=t-k_2}^{t-1} v_d / k_2}{\sum_{d=t-k_1}^{t-1} v_d / k_1} \times 100.$$

取  $k_1 = 12, k_2 = 26$ , 采用股票的成交量变异率作为输入特征, 即  $x_{t,23} = \text{VOSC}_t(12, 26)$ .

## 附录 2 定理 1 的证明过程

模型 (15) 的拉格朗日函数为:

$$L(w_{t,1}, \dots, w_{t,n}, \mu_t, \lambda_{t,1}, \dots, \lambda_{t,n}) = -\sum_{i=1}^n A_{t,i} w_{t,i} + \frac{\gamma}{2} \sum_{i=1}^n w_{t,i}^2 + \mu_t \left( \sum_{i=1}^n w_{t,i} - 1 \right) - \sum_{i=1}^n \lambda_{t,i} w_{t,i}. \quad (\text{A1})$$

其 KKT 条件为:

$$-A_{t,i} + \gamma w_{t,i} + \mu_t - \lambda_{t,i} = 0, \quad i = 1, \dots, n, \quad (\text{A2})$$

$$\sum_{j=1}^n w_{t,j} - 1 = 0, \quad (\text{A3})$$

$$\lambda_{t,i} w_{t,i} = 0, \quad i = 1, \dots, n, \quad (\text{A4})$$

$$\lambda_{t,i} \geq 0, \quad i = 1, \dots, n. \quad (\text{A5})$$

首先, 假定  $w_{t,1} = \dots = w_{t,k-1} = 0$  和  $w_{t,n}, \dots, w_{t,k} > 0$ , 其中  $k$  的取值将在后续讨论中给出. 由式 (A4) 得  $\lambda_{t,k} = \dots = \lambda_{t,n} = 0$ . 根据式 (A2), 得:

$$\lambda_{t,i} = \mu_t - A_{t,i}, \quad i = \{1, \dots, k-1\}, \quad (\text{A6})$$

$$w_{t,i} = \frac{A_{t,i} - \mu_t}{\gamma}, \quad i = \{k, \dots, n\}. \quad (\text{A7})$$

将式 (A7) 代入式 (A3), 得:

$$\sum_{j=1}^n w_{t,j} - 1 = \sum_{j=k}^n w_{t,j} - 1 = \frac{\sum_{j=k}^n A_{t,j} - (n-k+1)\mu_t}{\gamma} - 1 = 0 \Rightarrow \mu_t = \frac{\sum_{j=k}^n A_{t,j} - \gamma}{n-k+1}. \quad (\text{A8})$$

接着, 将式 (A8) 代入式 (A6) 和 (A7), 得:

$$\lambda_{t,i} = \frac{\sum_{j=k}^n (A_{t,j} - A_{t,i}) - \gamma}{n-k+1}, \quad i \in \{1, \dots, k-1\}, \quad (\text{A9})$$

$$w_{t,i} = \frac{\sum_{j=k}^n (A_{t,i} - A_{t,j}) + \gamma}{\gamma(n-k+1)}, \quad i \in \{k, \dots, n\}. \quad (\text{A10})$$

最后, 证明当  $k = \inf\{i : \sum_{j=i}^n (A_{t,j} - A_{t,i}) < \gamma\}$  时, 有  $\lambda_{t,1}, \dots, \lambda_{t,k-1} \geq 0$  和  $w_{t,k}, \dots, w_{t,n} > 0$ . 由于  $A_{t,1} \leq \dots \leq A_{t,k-1}$ , 有  $\lambda_{t,1} \geq \dots \geq \lambda_{t,k-1}$  和  $w_{t,k} \leq \dots \leq w_{t,n}$ . 因此, 只需保证  $\lambda_{t,k-1} \geq 0$  和  $w_{t,k} > 0$ . 记  $S(i) = \sum_{j=i}^n (A_{t,j} - A_{t,i})$ ,  $i = 1, \dots, n$ . 显然,  $S(i)$  关于  $i$  单调不减. 根据式 (A9) 和 (A10), 有

$$\lambda_{t,k-1} = \frac{S(k-1) - \gamma}{n-k+1}, \quad w_{t,k} = \frac{-S(k) + \gamma}{\gamma(n-k+1)}.$$

此时, 只需要证明  $S(k-1) - \gamma \geq 0$  和  $-S(k) + \gamma > 0$ . 假定  $k = \inf\{i : \sum_{j=i}^n (A_{t,j} - A_{t,i}) < \gamma\} = \inf\{i : S(i) < \gamma\}$ . 可以看到,  $k$  是满足  $S(i) < \gamma$  的最小整数. 由于  $S(k)$  关于  $k$  单调不减, 有  $S(k-1) \geq \gamma$  和  $S(k) < \gamma$ . 因此, 有

$$k = \inf\{i : S(i) < \gamma\} \Rightarrow S(k-1) - \gamma \geq 0 \Rightarrow \lambda_{t,k-1} \geq 0 \Rightarrow \lambda_{t,1} \geq \dots \geq \lambda_{t,k-1} \geq 0, \quad (\text{A11})$$

$$k = \inf\{i : S(i) < \gamma\} \Rightarrow -S(k) + \gamma > 0 \Rightarrow w_{t,k} > 0. \Rightarrow w_{t,n} \geq \dots \geq w_{t,k} > 0. \quad (\text{A12})$$

综上, 式 (16) 中的解满足模型所有的 KKT 条件.

证毕.